

Une approche statistique pour de l'apprentissage par renforcement et des réseaux stochastiques

Victor Boone


3 Avril 2026

Auditions CNRS, Section 2

Mon parcours


2019	Théorie des jeux [WINE] Boone, Piliouras (2019) <i>From Darwin to Poincaré and von Neumann: Recurrence and Cycles in Game Theory</i>	SUTD (Singapour, Stage)
2021	Apprentissage d'ordre supérieur [AISTATS] Boone, Gaujal (2023) <i>Identification of Blackwell Optimal Policies for Deterministic MDPs</i> [ICML] Boone, Gaujal (2023) <i>The Regret of Exploration and the Control of Bad Episodes in Reinforcement Learning</i> [NeurIPS] Boone, Mertikopoulos (2023) <i>The equivalence of dynamic and strategic stability under regularized learning in games</i> [Preprint] Boone (2023) <i>The Sliding Regret in Stochastic Bandits: Discriminating Index and Randomized Policies</i>	LIG (Grenoble, Thèse)
	Minimisation de regret [NeurIPS] Boone, Zhang (2024) <i>Achieving Tractable Minimax Optimal Regret in Average Reward MDPs</i>	
Nov. 2024	[Preprint] Boone, Maillard (2025) <i>The regret lower bound for communicating Markov Decision Processes</i>	Soutenance de thèse
Jan. 2025	[COLT] Boone, Gaujal (2025) <i>Logarithmic Regret of Exploration in Average Reward Markov Decision Processes</i> [Preprint] Boone (2025) <i>Asymptotically optimal regret in communicating Markov decision processes</i>	LIG (Grenoble, PostDoc)
Sep. 2025	[AISTATS] Boone, Tuynman (2026) <i>Towards Blackwell Optimality: Bellman Optimality Is All You Can Get</i>	IRIT (Toulouse, PostDoc)
(aujourd'hui)	Réseaux stochastiques	

Principe moteur de ma recherche



Une **approche statistique** pour faire
de l'**apprentissage par renforcement**


Là où tout commence : le **bandit manchot**



$\mathcal{A}$: ensemble de bras

ν_a : distribution des
récompenses du bras a

Là où tout commence : le **bandit manchot**




$\mathcal{A}$: ensemble de bras

ν_a : distribution des récompenses du bras a

À chaque instant de temps $t \geq 1$:

Étape 1 :

Je tire un bras
 A_t



Étape 2 :

Je reçois une récompense
 $R_t \sim \nu_{A_t}$

Notre objectif : Maximiser

$$\mathbb{E}[R_1 + \dots + R_T] .$$




Une métrique d'apprentissage : le regret

Une métrique d'apprentissage de référence : le regret.

Score avec oracle :

$$T\mu^*$$

- T : horizon temporel
- μ^* : récompense moyenne du meilleur bras



Score de l'apprenant :

$$R_1 + \dots + R_T$$

- T : horizon temporel
- μ^* : récompense moyenne du meilleur bras

$$\text{Regret : } \text{Reg}(T) := \mathbb{E} \left[T\mu^* - \sum_{t=1}^T R_t \right]$$

Paysage de la théorie (asymptotique) des **bandits manchots**

Trois approches

Approche *minimax* :

$$\sup_{\nu \text{ bandit}} \text{Reg}(T; \nu) \leq ?$$

Approche *fréquentiste* :

$$\text{Reg}(T; \nu) \leq ?$$

Approche *bayésienne* :

$$\int \text{Reg}(T; \nu) d\mathbb{P}(\nu) \leq ?$$



Paysage de la théorie (asymptotique) des **bandits manchots**

Trois approches

Approche **minimax** :



$$\sup_{\nu \text{ bandit}} \text{Reg}(T; \nu) \leq ?$$

Approche **fréquentiste** :

$$\text{Reg}(T; \nu) \leq ?$$


Approche **bayésienne** :

$$\int \text{Reg}(T; \nu) d\mathbb{P}(\nu) \leq ?$$



Quid de l'apprentissage par renforcement ?

Paysage de la théorie des **processus de décision markoviens** (PDMs)



États $\mathcal{S}$, actions $\mathcal{A}$

$\nu_{s,a} \in \mathcal{P}(\mathbb{R})$: distribution de récompenses de la paire (s, a)

$p_{s,a} \in \mathcal{P}(\mathcal{S})$: **noyau de transition** de la paire (s, a)

Solution “avec oracle”


On ne parle plus de **bras optimal** $a^* \in \mathcal{A}$
mais de **politique optimale** $\pi^* \in \mathcal{S} \rightarrow \mathcal{A}$.

- Chaque politique π a un **gain**

$$g_\pi := \lim_{T \rightarrow \infty} \frac{1}{T} \mathbb{E}_\pi [R_1 + \dots + R_T] :$$

- La politique optimale atteint le **gain optimal**

$$g^* := \sup_{\pi} g_\pi .$$



Paysage de la théorie des processus de décision markoviens (PDMs)

Solution “avec oracle”



On ne parle plus de **bras optimal** $a^* \in \mathcal{A}$ mais de **politique optimale** $\pi^* \in \mathcal{S} \rightarrow \mathcal{A}$.

- Chaque politique π a un **gain**


$$g_\pi := \lim_{T \rightarrow \infty} \frac{1}{T} \mathbb{E}_\pi [R_1 + \dots + R_T] :$$

- La politique optimale atteint le **gain optimal**

$$g^* := \sup_{\pi} g_\pi .$$



L'objectif véritable : décrire des solutions **canoniques**




Processus de décision markovien

=



Bandit

+



Chaîne de Markov

L'objectif véritable : décrire des solutions **canoniques**

- $N_{s,a}(t)$ = nombre de visites de (s, a) jusqu'à l'instant t
- **Théorème.** Si $\text{Reg}(T; M) = O(\log(T))$, alors il existe des vecteurs μ, μ' tels que

$$N(T) = \mu \cdot T + \mu' \cdot \log(T) + o(\log(T)) ,$$

avec $\inf_{M^\dagger \in \text{Cnf}(M)} \sum_{s,a} \mu'_{s,a} \text{KL}(M_{s,a} \| M_{s,a}^\dagger) \geq 1$ (structure **informationnelle** type **bandit**)
et $\mu, \mu' \in \text{Inv}(M)$. (structure type **chaîne de Markov**)

- Tout $\mu, \mu' \in \text{Inv}(M)$ peut être **encodé** par une politique π en μ^π .

L'objectif véritable : décrire des solutions **canoniques**

- $N_{s,a}(t)$ = nombre de visites de (s, a) jusqu'à l'instant t
- **Théorème.** Si $\text{Reg}(T; M) = O(\log(T))$, alors il existe des vecteurs μ, μ' tels que

$$N(T) = \mu \cdot T + \mu' \cdot \log(T) + o(\log(T)) ,$$

avec $\inf_{M^\dagger \in \text{Cnf}(M)} \sum_{s,a} \mu'_{s,a} \text{KL}(M_{s,a} \| M^\dagger_{s,a}) \geq 1$ (structure **informationnelle** type **bandit**)
et $\mu, \mu' \in \text{Inv}(M)$. (structure type **chaîne de Markov**)

- Tout $\mu, \mu' \in \text{Inv}(M)$ peut être **encodé** par une politique π en μ^π .

Théorème (Boone, Maillard, 2025). Pour toute PDM *communicante* M , le regret fréquentiste de tout algorithme consistant satisfait $\text{Reg}(T; M) \geq C(M) \log(T)$, où

$$C(M) := \inf_{\text{politique } \pi} \sup_{M^\dagger \in \text{Cnf}(M)} \left\{ \frac{g^* - g_\pi}{\sum_{(s,a) \in \mathcal{S} \times \mathcal{A}} \mu_{s,a}^\pi \text{KL}(M_{s,a} \| M^\dagger_{s,a})} \right\} .$$

L'objectif véritable : décrire des solutions **canoniques**

- $N_{s,a}(t)$ = nombre de visites de (s, a) jusqu'à l'instant t

Véritable objectif : Caractériser le comportement des algorithmes optimaux et trouver des **solutions canoniques**.

Exemple :


$$C(M) = \inf_{\text{politique } \pi} \sup_{M^\dagger \in \text{Cnf}(M)} \left\{ \frac{g^* - g_\pi}{\sum_{(s,a) \in \mathcal{S} \times \mathcal{A}} \mu_{s,a}^\pi \text{KL}(M_{s,a} \parallel M_{s,a}^\dagger)} \right\}$$

décrit le *meilleur comportement possible* des algorithmes d'apprentissage dans le monde *fréquentiste*.

Mon **projet de recherche**

1 Compléter le paysage


(PDMs finis)



- ? Quid du monde bayésien ?
- ? Compatibilité de ces mondes ?
- ? Efficacité pratique des algorithmes asymptotiquement optimaux ?
- ? Algorithmes canoniques ?

1 Compléter le paysage

(PDMs finis)



- ? Quid du monde bayésien ?
- ? Compatibilité de ces mondes ?
- ? Efficacité pratique des algorithmes asymptotiquement optimaux ?
- ? Algorithmes canoniques ?

2 Et la complexité ?

- Changements de mesures : purement mathématiques.
- Le regret fréquentiste

$$C(\text{PDM}) \log(T)$$


n'est atteint par aucun algorithme de complexité raisonnable.

Q-Learning et Policy Gradient

- ✓ Utilisés en pratique
- ✓ Légers en mémoire et calculs
- ✗ Non canoniques (hyperparamètres)
- ✗ Versions "théoriques" inutilisables
- ✗ Pas optimaux
- ? Canoniques, utilisables, optimaux ?

1 Compléter le paysage

(PDMs finis)



- ? Quid du monde bayésien ?
- ? Compatibilité de ces mondes ?
- ? Efficacité pratique des algorithmes asymptotiquement optimaux ?
- ? Algorithmes canoniques ?

2 Et la complexité ?

- Changements de mesures : purement mathématiques.
- Le regret fréquentiste

$$C(\text{PDM}) \log(T)$$


n'est atteint par aucun algorithme de complexité raisonnable.

Q-Learning et Policy Gradient

- ✓ Utilisés en pratique
- ✓ Légers en mémoire et calculs
- ✗ Non canoniques (hyperparamètres)
- ✗ Versions "théoriques" inutilisables
- ✗ Pas optimaux
- ? Canoniques, utilisables, optimaux ?

3 PDMs de grande taille (et réseaux stochastiques)

- ✗ PDMs petites et finies : peu d'applications
- ✓ PDMs dénombrables = réseaux



- ? Approche informationnelle ?
- ? Paysage du regret pour ces PDMs ?
- ✓ Regret borné parfois possible

Mon projet de recherche

1

LIP — UMR 5668



- Aurélien Garivier
- Rémi Gribonval

2


CRISTAL — UMR 9189



- Rémy Degenne
- Émilie Kaufmann
- Odalric-Ambrym Maillard

3

IRIT — UMR 5505



- Urtzi Ayesta
- Céline Comte
- Matthieu Jonckheere